

실시간 객체 탐지를 위한 딥러닝 기술 분석

Faster R-CNN

RPN 기반 실시간 객체 탐지

김유

목차

01

발표 개요 및 핵심 요약

02

연구 배경

03

핵심 기술 - RPN

04

핵심 기술 - Anchor Boxes

05

성능 비교 및 실험 결과

06

결론 및 의의

발표 개요 및 핵심 요약

01

실시간객체탐지를위한Faster R-CNN

- 객체 탐지(Object Detection) 기술 분석
- Region Proposal Network를 활용한 혁신
- 실시간 처리가 가능한 통합 시스템
- 정확도와 속도의 균형 달성

02

Region Proposal Network도입

- 영역 제안을 위한 딥러닝 네트워크
- 기존 외부 알고리즘 의존성 제거
- GPU 기반의 빠른 연산 처리
- 탐지 네트워크와 특징 공유

03

객체탐지 속도 병목 현상 해결

- 기존 Selective Search의 한계 극복
- CPU 기반에서 GPU 기반으로 전환
- 영역 제안 시간을 1.5초에서 0.01초로 단축
- 전체 시스템의 처리 속도 향상

04

통합네트워크를 통한 정확도 향상

- 단일 통합 네트워크 구조 실현
- 컨볼루션 특징 공유로 연산 효율화
- PASCAL VOC 2007에서 69.9% mAP 달성
- Fast R-CNN 대비 3% 정확도 향상

R-CNN 시리즈의 발전 과정

1


R-CNN

2014년 등장한 첫 번째 모델로,
Selective Search를 통해
약 2,000개의 후보 영역을 생성하고
각 영역마다 CNN을 실행

2

Fast R-CNN

전체 이미지에서 한 번만 특징을 추출하고
RoI Pooling을 도입하여
속도를 크게 개선




3


Faster R-CNN

Region Proposal Network(RPN)
를 도입하여 영역 제안까지 신경망으로
통합한 완전한 end-to-end 시스템


R-CNN



Fast R-CNN



Faster R-CNN



Faster R-CNN?




기존 모델의 한계점

SPPnet과 Fast R-CNN은

객체 탐지 단계는 빨라졌으나

영역 제안은 여전히 느낌

02



영역 제안 단계의 병목

Selective Search 등 외부 알고리즘 의존

전체 속도의 병목현상 유발

03




CPU 기반의 속도 제한

CPU 기반
Selective Search 사용

약 1,510ms 소요

실시간 처리 불가능

04




딥러닝 기반 해결책

RPN 도입으로 GPU 기반 처리 실현

컨볼루션 특징 공유

연산 비용 획기적 절감

RPN (Region Proposal Network)



01

완전 컨볼루션 네트워크 (FCN) 구조


- 이미지의 컨볼루션 특징 맵을 입력으로 사용
- 효율적인 end-to-end 학습 가능
- GPU 기반의 빠른 연산 처리

02

객체 위치와 존재 확률 동시 예측

- 객체의 위치 정보 예측
- 객체 존재 확률 (Objectness Score) 계산
- 두 가지 정보를 동시에 출력
- 정확한 영역 제안 생성

RPN (Region Proposal Network)



03

슬라이딩 윈도우 방식의 작동 원리


- 특징 맵 위를 슬라이딩 윈도우로 탐색
- 각 위치에서 후보 영역 제안
- 효율적인 전체 이미지 커버
- 빠른 처리 속도 실현

04

영역제안과 탐지의 통합 구현

- 하나의 네트워크 안에서 영역 제안과 탐지 수행
- Unified Network 구조 실현
- 특징 공유로 연산 효율 극대화
- 실시간 객체 탐지 가능

Anchor Boxes




다중 스케일 앵커

3가지 스케일(128^2 , 256^2 , 512^2)과
3가지 비율(1:1, 1:2, 2:1)을 조합하여
총 9개의 앵커 박스를 각 위치에서 생성



이미지 피라미드 불필요

고정된 크기의 특징 맵에서
다양한 크기의 객체를 포착하여
이미지 크기 조절 없이 효율적으로 탐지



이동 불변성 보장

객체가 이미지 내 어디에 위치하든
동일한 방식으로 탐지 가능한 일관성
있는 처리 방식

Anchor Boxes의 장점

파라미터수감소

01

- 이동 불변성 특성으로 인해 파라미터 수가 크게 감소
 - 모델의 전체 크기가 축소되어 메모리 사용량 최소화
-

효율적인연산

02

- 이미지 피라미드 방식 대비 훨씬 효율적인 연산 구조
 - GPU 자원을 최적으로 활용하여 빠른 처리 속도 달성
-

일관된탐지성능

03


- 객체가 이미지 내에서 이동하더라도 동일한 방식으로 탐지 가능
 - 위치에 관계없이 안정적인 성능 유지
-

우수한비용효율성

04

- 필터 피라미드 방식과 비교했을 때 월등한 효율성
 - 적은 연산 비용으로 높은 정확도 달성
-

Training



Training

01

CNN + RPN 학습

객체 후보 영역(Proposal) 생성

02

CNN + Fast R-CNN 학습

RPN Proposal 기반 객체 분류/위치 보정

03

CNN 고정, RPN 미세조정

Proposal을 Fast R-CNN에 맞게 개선

04

CNN 고정, Fast R-CNN 미세조정

단일 통합 네트워크 완성

최종 결과

CNN + RPN + Fast R-CNN

Training

RPN Loss Function

Multi-task Loss

하나의 네트워크가 여러 개의 서로 다른 작업을 동시에 학습하도록
여러 개의 loss를 합쳐서 최적화 하는 방식

RPN

Anchor

분류
(Classification)

회귀
(Regression)

$IoU \leq 0.3$
배경
(Negative)

객체
(Positive)

나머지
(Ignore)

$IoU \geq 0.7$ & 가장 높은 IoU를 가진 Anchor

정답박스(GT)로 가기 위한
offset 예측

$$t_x^* = (x^* - x_a) / w_a, \quad t_y^* = (y^* - y_a) / h_a, \\ t_w^* = \log(w^* / w_a), \quad t_h^* = \log(h^* / h_a),$$

회귀 목표

Anchor
Training

IoU

두 개의 Bounding Box가 얼마나 겹치는지를
수치로 표현한 지표

$$L(\{p_i\}, \{t_i\}) = \frac{1}{N_{cls}} \sum_i L_{cls}(p_i, p_i^*) \\ + \lambda \frac{1}{N_{reg}} \sum_i p_i^* L_{reg}(t_i, t_i^*).$$

RPN의 작동 원리



신경망 기반 영역 제안

01

특징 맵 생성

입력 이미지를 CNN으로 처리하여 공유 특징 맵 추출

02

슬라이딩 윈도우


특징 맵 위를 3×3 윈도우로 순회하며 각 위치 분석

03

스코어 계산

각 앵커에 대해 객체 존재 확률과 바운딩 박스 좌표 예측

기존 모델과의 비교 분석





Fast R-CNN

영역 제안: Selective Search 사용 (외부/CPU 기반)

제안 속도: 약 1,510ms 소요

전체 FPS: 0.5 fps

네트워크 구조: 이원화된 구조로 비효율적



Faster R-CNN

영역 제안: RPN 사용 (내부/GPU 기반)

제안 속도: 약 10ms로 대폭 단축

전체 FPS: 5 fps (VGG-16 기준)

네트워크 구조: 단일 통합 네트워크로 효율성 극대화

실험 결과 및 성능 (1)

01

속도 향상

- VGG-16 모델 사용 시 전체 시스템 속도가 198ms로 단축
- 기존 모델 대비 획기적인 속도 개선
- GPU 기반 통합 처리의 효과

02

실시간성

- 198ms의 처리 속도로 실시간에 가까운 성능 달성
- 5 fps의 프레임 속도 구현
- 실용적인 응용 가능성 확보

03

PASCAL VOC 2007 결과

- PASCAL VOC 2007 데이터셋에서 69.9% mAP 기록
- 당시 주요 벤치마크에서 우수한 성과
- 객체 탐지 정확도의 새로운 기준 제시

04

정확도 향상

- Fast R-CNN의 66.9% 대비 3% 향상된 69.9% mAP
- 속도와 정확도를 동시에 개선
- 효율성과 성능의 균형 달성

실험 결과 및 성능 (2)

01




MS COCO 데이터셋

MS COCO 데이터셋에서
최고 수준 달성

복잡한 장면에서도 우수한 성능
다양한 객체 탐지 능력 입증

02



제안 영역 효율성

이미지당 단 300개의 제안
영역만 사용

적은 제안 수로도 높은
정확도 유지

연산 효율성 극대화

03




벤치마크 성과

주요 벤치마크에서
State-of-the-art 성과 기록

당시 최고 수준의
객체 탐지 성능

학계와 산업계에서 인정

04



효율성과 정확도

속도와 정확도의
최적 균형 달성

실용성과 성능을 모두 만족

실제 응용 가능한 시스템 구현

결론 및 의의

Faster R-CNN은 영역제안을 딥러닝으로 통합하여 속도 문제를 해결

RPN으로 CPU Selective Search 병목 제거

통합 네트워크로 GPU 기반 실시간 처리 구현

3D 탐지·인스턴스 분할 등 후속 연구의 기초 제공

상용 시스템에 적용되어 성능 입증

객체 탐지 분야의 패러다임을 전환한 성과
